Inferência Estatística - Parte II

Resumo para a Prova: Testes de Hipóteses e Regressão

Feliz Happy Happy

Curso de Economia

Resumo do Conteúdo

Este material é a continuação do resumo de Estatística, focado agora na tomada de decisão (Testes de Hipóteses), comparação entre populações e introdução à econometria com Regressão Linear Simples. Baseado nos Capítulos 12, 13 e 16. Bons estudos!

Material de Apoio Acadêmico

Sumário

1 Testes de Hipóteses **3**
1.1 Estrutura Fundamental . . . 3
1.2 A Matriz de Decisão e Erros . . . 3
1.3 Critérios de Decisão . . . 3

2 Principais Estatísticas de Teste **3**
2.1 Para a Média (μ) . . . 4
2.2 Para Proporções (p) . . . 4
2.3 Para a Variância (σ^2) . . . 4

3 Inferência para Duas Populações (Cap. 13) **4**
3.1 Comparação de Duas Médias . . . 4
3.1.1 Caso 1: Variâncias Conhecidas — Teste Z . . . 5
3.1.2 Caso 2: Variâncias Desconhecidas, mas Iguais — Teste t Combinado 5
3.1.3 Caso 3: Variâncias Desconhecidas e Diferentes — Teste de Welch . 5
3.2 Comparação de Duas Variâncias — Teste F . . . 7
3.3 Comparação de Duas Proporções . . . 7
3.4 Resumo Prático: Qual teste usar? . . . 8
3.5 Exemplo Completo Passo a Passo . . . 8
3.6 Cuidados em Inferência para Duas Populações . . . 8

4 Regressão Linear **9**
4.1 Regressão Linear . . . 9
4.2 Tipos de Regressão . . . 9
4.2.1 1. Regressão Linear Simples . . . 10
4.2.2 2. Regressão Linear Múltipla . . . 10
4.3 Definição dos Coeficientes (Estimação) . . . 10
4.4 Estimação dos Parâmetros por Mínimos Quadrados (MQ) . . . 11
4.4.1 1. Derivação em relação ao Intercepto (α) . . . 11
4.4.2 2. Derivação em relação à Inclinação (β) . . . 11
4.4.3 3. Demonstração Intuitiva de $\hat{\beta}$ . . . 12
4.5 Avaliação do Modelo: Decomposição da Variabilidade . . . 12
4.5.1 Coeficiente de Determinação (R^2) . . . 12
4.5.2 Exemplo Prático Passo a Passo (Escolaridade vs. Renda) . . . 12
4.6 Pressupostos de uma Regressão Linear . . . 13

5 Resolução das Questões Verdadeiro ou Falso **14**
5.1 Questão 1 – Julgue as afirmativas: . . . 14
5.2 Questão 2 – Notas de matemática e curso noturno . . . 15
5.3 Questão 3 – Proporção de consumidores satisfeitos . . . 16

6 Questão 1 – Teste de hipóteses e p-valor **17**

7 Questão 2 – Inferência Bayesiana **18**

8 Questão 3 – Relação entre teste de hipótese e intervalo de confiança **19**

9 Questão 4 – Interpretação de intervalo de confiança **21**

10 Questão 5 – Teste para média com variância conhecida **22**

11 Questão 6 – Teste F para igualdade de variâncias **23**

12 Questão 7 – Teste para coeficiente de regressão **24**

13 Questão 8 – Cálculo do estimador MQO **25**

1 Testes de Hipóteses

Enquanto o Intervalo de Confiança é uma estimativa *quantitativa* (um intervalo de valores), o Teste de Hipóteses é uma inferência *qualitativa*: buscamos aceitar ou rejeitar uma afirmação sobre o mundo.

1.1 Estrutura Fundamental

Tudo começa com a definição de dois estados de mundo concorrentes:

- **Hipótese Nula (H_0):** É a hipótese do "status quo" ou da ausência de efeito (ex: a moeda é honesta, o remédio não faz efeito).
- **Hipótese Alternativa (H_1):** É a hipótese de pesquisa, o que queremos provar (ex: a moeda é viciada, o remédio funciona).

1.2 A Matriz de Decisão e Erros

Como decidimos com base em uma amostra, estamos sujeitos a erros. A tabela abaixo resume as possibilidades:

	H_0 **é Verdadeira**	H_0 **é Falsa**
Rejeitar H_0	**Erro Tipo I (α)** (Falso Positivo)	Decisão Correta (Poder) $(1-\beta)$
Não Rejeitar H_0	Decisão Correta $(1-\alpha)$	**Erro Tipo II (β)** (Falso Negativo)

- **Nível de Significância (α):** É a probabilidade de cometer o Erro Tipo I. Fixamos este valor (geralmente 5% ou 1%) para controlar o risco de "alarme falso".
- **Poder do Teste ($1-\beta$):** É a capacidade do teste de detectar um efeito quando ele realmente existe. Queremos maximizar o poder.

1.3 Critérios de Decisão

Para decidir, comparamos os dados com a teoria usando um de dois métodos equivalentes:

1. **Região Crítica:** Se a estatística calculada cair na zona extrema (cauda) determinada pelo α, rejeitamos H_0.
2. **P-valor:** É a probabilidade de observar algo tão extremo quanto nossa amostra, assumindo que H_0 é verdade.
   - Se **P-valor** $\leq \alpha \rightarrow$ Rejeitamos H_0 (O evento é raro demais para ser sorte).
   - Se **P-valor** $> \alpha \rightarrow$ Não Rejeitamos H_0.

2 Principais Estatísticas de Teste

A escolha da fórmula depende do que sabemos sobre a população.

2.1 Para a Média (μ)

- **Variância Populacional (σ^2) Conhecida:** Usamos a **Normal (Z)**.

$$Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

- **Variância Populacional Desconhecida:** Estimamos com S e usamos a **t-Student**.

$$t = \frac{\bar{x} - \mu_0}{S/\sqrt{n}}$$

2.2 Para Proporções (p)

Para grandes amostras, usamos a aproximação pela Normal:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

2.3 Para a Variância (σ^2)

Usamos a distribuição **Qui-Quadrado (χ^2)** com $n-1$ graus de liberdade:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$$

3 Inferência para Duas Populações (Cap. 13)

Nesta seção vamos aprender a comparar duas populações de forma estatística. Isso é fundamental em Economia, pois muitas perguntas de pesquisa envolvem comparações:

- O salário médio de homens e mulheres é igual?
- Um programa de qualificação profissional aumenta a renda?
- A produtividade de duas fábricas é a mesma?
- A volatilidade de dois ativos financeiros difere?

Vamos cobrir três grandes tópicos:

1. Comparação de duas médias (Testes Z e t).
2. Comparação de duas variâncias (Teste F).
3. Comparação de duas proporções (Teste Z para proporções).

3.1 Comparação de Duas Médias

Aqui queremos testar se a média de uma população (μ_1) é igual à média de outra (μ_2).

3.1.1 Caso 1: Variâncias Conhecidas — Teste Z

Quando conhecemos as variâncias populacionais σ_1^2 e σ_2^2 (raro na prática, mas útil didaticamente).

- Hipóteses:
$$H_0 : \mu_1 = \mu_2 \quad \text{vs} \quad H_1 : \mu_1 \neq \mu_2$$
- Estatística de teste:
$$Z = \frac{(\bar{X}_1 - \bar{X}_2) - 0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$
- Distribuição sob H_0: $Z \sim N(0, 1)$.

Exemplo econômico: Comparação de preços médios de energia entre duas regiões, com variâncias conhecidas de levantamentos oficiais.

3.1.2 Caso 2: Variâncias Desconhecidas, mas Iguais — Teste t Combinado

Quando não conhecemos as variâncias, mas acreditamos que sejam iguais ($\sigma_1^2 = \sigma_2^2$).

- Primeiro estimamos a **variância combinada (pooled variance)**:
$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$
- Estatística de teste:
$$t = \frac{\bar{X}_1 - \bar{X}_2}{S_p\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$
- Distribuição sob H_0: $t \sim t_{n_1+n_2-2}$.

Exemplo: Comparar salários médios de economistas do setor público e privado, assumindo variabilidade semelhante.

3.1.3 Caso 3: Variâncias Desconhecidas e Diferentes — Teste de Welch

Quando as variâncias são diferentes (ex.: microempresas vs. grandes empresas).

- Estatística de teste:
$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$
- Graus de liberdade aproximados (fórmula de Welch–Satterthwaite):
$$\nu \approx \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$
- Distribuição sob H_0: $t \sim t_\nu$.

3.1.4 Caso 4: Amostras Pareadas (Dependentes)

Diferença Conceitual

Diferente dos casos anteriores, aqui as amostras **não são independentes**. Medimos a **mesma unidade** duas vezes (ex: Antes vs. Depois, Filho vs. Pai). Não comparamos a média do Grupo 1 contra a média do Grupo 2, mas sim a **média das diferenças**.

Passo 1: Definir a variável Diferença (D)
Para cada par, calculamos $d_i = X_{1i} - X_{2i}$. O problema se resume a um Teste t para uma única média (a média das diferenças, μ_d).

Hipóteses:

$$H_0 : \mu_d = 0 \quad \text{(Não há mudança/diferença)}$$

$$H_1 : \mu_d \neq 0 \quad \text{(Existe diferença - Bicaudal)}$$

Estatística de Teste:

$$t = \frac{\bar{d} - 0}{S_d/\sqrt{n}}$$

Onde:

- $\bar{d}$: Média amostral das diferenças.
- S_d: Desvio-padrão amostral das diferenças.
- n: Número de pares (não o total de observações).
- Graus de liberdade: $n - 1$.

Exemplo Numérico (Treinamento):
Notas de 5 alunos antes e depois de um curso.

Aluno	Antes (X_1)	Depois (X_2)	Diferença ($d = X_2 - X_1$)
A	5	7	+2
B	6	8	+2
C	7	7	0
D	4	6	+2
E	5	9	+4

- Média das diferenças ($\bar{d}$): $(2 + 2 + 0 + 2 + 4)/5 = 2,0$.
- Desvio-padrão (S_d): Calculando, $S_d \approx 1,41$.
- Estatística t: $t = \frac{2,0}{1,41/\sqrt{5}} = \frac{2,0}{0,63} \approx 3,17$.

Se $t_{crit}(4gl) = 2,776$ (a 5%), como $3,17 > 2,776$, **rejeitamos** H_0. O curso teve efeito.

3.2 Comparação de Duas Variâncias — Teste F

Antes de comparar médias, pode ser útil verificar se as variâncias são iguais.

- Hipóteses:
$$H_0 : \sigma_1^2 = \sigma_2^2 \quad \text{vs} \quad H_1 : \sigma_1^2 \neq \sigma_2^2$$
- Estatística de teste (coloque a maior variância no numerador):
$$F = \frac{S_1^2}{S_2^2}$$
- Distribuição sob H_0: $F \sim F_{n_1-1,n_2-1}$.

Exemplo: Comparar a volatilidade de retornos de dois ativos financeiros.

Exemplo Prático (Risco de Investimentos):
Queremos saber se o Ativo A é mais volátil (arriscado) que o Ativo B.

- **Dados:** Amostras de retornos mensais.
- Ativo A: $n_1 = 16$, Variância $S_1^2 = 25$.
- Ativo B: $n_2 = 21$, Variância $S_2^2 = 10$.

Cálculo: Sempre coloque a **maior** variância no numerador.
$$F = \frac{S_1^2}{S_2^2} = \frac{25}{10} = 2,5$$

Decisão: Buscamos na tabela F com $gl_1 = 15$ e $gl_2 = 20$. Suponha $\alpha = 5\%$.

- Se o valor crítico $F_{tab} \approx 2,20$.
- Como $F_{calc}(2,5) > F_{tab}(2,20)$, **rejeitamos** H_0.

Conclusão: As variâncias são estatisticamente diferentes. O Ativo A é mais arriscado.

3.3 Comparação de Duas Proporções

Para variáveis binárias (ex.: proporção de inadimplentes, acesso à internet).

- Hipóteses:
$$H_0 : p_1 = p_2 \quad \text{vs} \quad H_1 : p_1 \neq p_2$$
- Estatística de teste (amostras grandes):
$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$
onde $\hat{p} = \frac{X_1+X_2}{n_1+n_2}$ é a proporção combinada.
- Distribuição sob H_0: $Z \sim N(0,1)$.

Exemplo: Comparar a proporção de domicílios com internet em áreas urbanas e rurais.

3.4 Resumo Prático: Qual teste usar?

Pergunta	Teste indicado
As médias são iguais?	
– Variâncias conhecidas	Teste Z
– Variâncias desconhecidas, iguais	Teste t combinado
– Variâncias desconhecidas, diferentes	Teste de Welch
As variâncias são iguais?	Teste F
As proporções são iguais?	Teste Z para proporções

3.5 Exemplo Completo Passo a Passo

Vamos comparar as médias de duas populações com variâncias desconhecidas e iguais.

Dados:

- Grupo 1 (Setor Público): $n_1 = 60$, $\bar{X}_1 = 7200$, $S_1 = 1500$.
- Grupo 2 (Setor Privado): $n_2 = 55$, $\bar{X}_2 = 8200$, $S_2 = 1600$.

Passo 1 — Hipóteses:

$$H_0 : \mu_1 = \mu_2 \quad \text{vs} \quad H_1 : \mu_1 \neq \mu_2$$

Passo 2 — Variância combinada:

$$S_p^2 = \frac{(60-1)1500^2 + (55-1)1600^2}{60+55-2} \approx 2,398,141.6$$

Passo 3 — Estatística t:

$$t = \frac{7200 - 8200}{1548.59\sqrt{\frac{1}{60} + \frac{1}{55}}} \approx \frac{-1000}{289.09} \approx -3.459$$

Passo 4 — Decisão: Graus de liberdade: 113. Valor crítico bilateral ($\alpha = 5\%$): $t_{0.975,113} \approx 1.981$. Como $|t| = 3.459 > 1.981$, **rejeitamos** H_0.

Passo 5 — Conclusão: Há evidência estatística de que os salários médios diferem entre os setores público e privado.

3.6 Cuidados em Inferência para Duas Populações

- **Não confunda diferença com causalidade:** mesmo que as médias sejam diferentes, isso não prova que um fator causou a diferença.
- **Verifique a independência das amostras:** amostras pareadas exigem métodos diferentes.
- **Avalie a normalidade:** para amostras pequenas, a suposição de normalidade é importante.
- **Considere o tamanho do efeito:** além do p-valor, olhe para a magnitude da diferença (ex.: diferença de R$ 1000 no exemplo acima).

3.7 Tamanho do Efeito (Effect Size)

Não basta saber se existe diferença (p-valor); precisamos saber se a diferença é **relevante**. Para isso, usamos o d **de Cohen**.

$$d = \frac{\bar{x}_1 - \bar{x}_2}{S_{pooled}}$$

Onde S_{pooled} é o desvio-padrão combinado (ou use um dos desvios se forem parecidos). O valor representa quantos desvios-padrão as médias estão distantes uma da outra.

Tabela de Interpretação (Cohen)

Valor de d	Interpretação
0,20	Efeito Pequeno
0,50	Efeito Médio (Visível a olho nu)
0,80	Efeito Grande

Exemplo: Se o salário aumentou R$ 200, mas o desvio-padrão é R$ 1000, $d = 0,2$ (Efeito pequeno). Se o aumento foi R$ 800 com o mesmo desvio, $d = 0,8$ (Efeito grande).

4 Regressão Linear

Fonte: Material adaptado de @lasuliss

4.1 Regressão Linear

A regressão linear é um tipo de modelo supervisionado de regressão. Seu objetivo é prever um valor contínuo que pode assumir qualquer valor numérico dentro de um intervalo real.

Ela faz isso modelando a relação linear entre uma variável resposta (Y) e uma ou mais variáveis explicativas (X), buscando encontrar a **melhor equação** que minimize o erro mensurado por uma função de custo (a diferença entre os valores reais e previstos).

Função de Custo (MSE)

O objetivo é minimizar o *Mean Squared Error* (Erro Quadrático Médio):

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- n: Número total de amostras.
- $(y_i - \hat{y}_i)$: Erro (Diferença entre valor real e valor predito).

4.2 Tipos de Regressão

Existem dois tipos principais: simples e múltipla.

4.2.1 1. Regressão Linear Simples

É o caso em que há apenas um coeficiente/parâmetro associado a uma variável. O modelo estima um coeficiente para X, resultando em uma reta. É o caso de mais fácil visualização.

$$y_i = \underbrace{\beta_0}_{\text{Intercepto}} + \underbrace{\beta_1 x_i}_{\text{Coef. Angular}} + \underbrace{\varepsilon_i}_{\text{Erro}}$$

- **Variável Dependente (y_i):** O que queremos prever.
- **Variável Independente (x_i):** A variável explicativa.

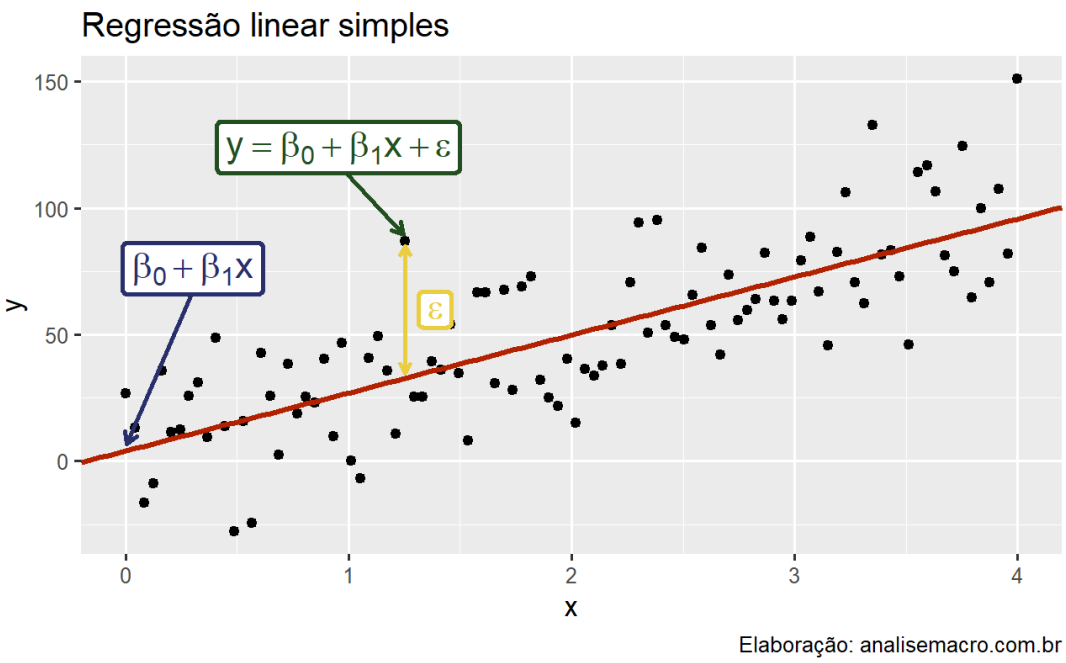

Figura 1: Componentes Visuais da Regressão Linear.

4.2.2 2. Regressão Linear Múltipla

É quando há **mais de um coeficiente** e **mais de uma variável independente** explicando a resposta $(x_1, x_2, ..., x_k)$.

- O módulo dos coeficientes aponta o poder explicativo de cada variável (qual é mais "importante").
- **Visualização:** Por ter múltiplas dimensões, deixa de ser uma reta 2D e passa a ser um hiperplano, dificultando a visualização gráfica.

4.3 Definição dos Coeficientes (Estimação)

Como os coeficientes (o impacto de cada variável) são determinados? Existem dois métodos principais:

1. **Método dos Mínimos Quadrados (MQO):** Determinístico.
2. **Gradiente Descendente:** Iterativo.

4.4 Estimação dos Parâmetros por Mínimos Quadrados (MQ)

Nosso objetivo é obter estimadores para α e β que tornem o erro o menor possível. Para isso, minimizamos a **Soma dos Quadrados dos Erros (SQE)**:

$$S(\alpha, \beta) = \sum_{i=1}^{n} [y_i - (\alpha + \beta x_i)]^2$$

Para encontrar o mínimo, calculamos as derivadas parciais e igualamos a zero.

4.4.1 1. Derivação em relação ao Intercepto (α)

Derivamos S em relação a α e igualamos a 0:

$$\frac{\partial S}{\partial \alpha} = -2 \sum (y_i - \alpha - \beta x_i) = 0$$

Dividindo por -2 e separando os somatórios:

$$\sum y_i - n\alpha - \beta \sum x_i = 0$$

Isolando α e sabendo que $\bar{y} = \sum y_i / n$ e $\bar{x} = \sum x_i / n$:

$$n\alpha = \sum y_i - \beta \sum x_i$$

$$\hat{\alpha} = \frac{\sum y_i}{n} - \beta \frac{\sum x_i}{n}$$

Estimador do Intercepto

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$$

A reta sempre passa pelo ponto médio $(\bar{x}, \bar{y})$.

4.4.2 2. Derivação em relação à Inclinação (β)

Derivamos S em relação a β e igualamos a 0:

$$\frac{\partial S}{\partial \beta} = -2 \sum x_i (y_i - \alpha - \beta x_i) = 0$$

Substituímos α por $(\bar{y} - \beta\bar{x})$ na equação:

$$\sum x_i (y_i - \bar{y}) - \beta \sum x_i (x_i - \bar{x}) = 0$$

Resolvendo para β, chegamos à fórmula da covariância sobre a variância:

Estimador da Inclinação

$$\hat{\beta} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)}$$

4.4.3 3. Demonstração Intuitiva de $\hat{\beta}$

A fórmula mostra que o coeficiente $\hat{\beta}$ depende de como X e Y variam juntos:

- **Numerador (Covariância):** Se X e Y sobem juntos, $\hat{\beta}$ é positivo.
- **Denominador (Variância de X):** Se X varia pouco, o denominador é pequeno e a estimativa explode (fica imprecisa). Precisamos de variabilidade em X para estimar o efeito.

4.5 Avaliação do Modelo: Decomposição da Variabilidade

Para saber se o modelo é bom, verificamos quanto da variação de Y ele consegue explicar. Partimos da identidade fundamental:

$$\mathbf{SQT} = \mathbf{SQR} + \mathbf{SQE}$$

1. **SQT (Soma de Quadrados Total):** A variabilidade total dos dados ($\sum(y_i - \bar{y})^2$).
2. **SQR (Soma de Quadrados da Regressão):** A parte que o modelo **explica** ($\sum(\hat{y}_i - \bar{y})^2$).
3. **SQE (Soma de Quadrados do Erro):** A parte que o modelo **não explica** ($\sum(y_i - \hat{y}_i)^2$).

4.5.1 Coeficiente de Determinação (R^2)

Mede a porcentagem da variância de Y explicada por X.

Fórmula do R^2

$$R^2 = \frac{SQR}{SQT} = 1 - \frac{SQE}{SQT}$$

- Varia entre 0 e 1. Quanto mais próximo de 1, melhor o ajuste.
- **Cuidado Econômico:** Um R^2 alto não prova causalidade (pode ser correlação espúria), e um R^2 baixo não invalida uma teoria (ex: dados de corte transversal costumam ter R^2 menor).

4.5.2 Exemplo Prático Passo a Passo (Escolaridade vs. Renda)

Para entender como essas somas de quadrados são calculadas na prática, vamos usar o exemplo numérico do material.

Dados: Amostra de 5 indivíduos.

- Médias: $\bar{X} = 13.8$ e $\bar{Y} = 4.04$.
- Equação da Reta (MQO): $\hat{Y} = -1.4618 + 0.3987X$.

Passo 1: Calcular os valores previstos ($\hat{Y}$) e os erros (e)

Indiv.	X	Y	$\hat{Y}$ (Previsto)	$e = Y - \hat{Y}$
1	8	2.0	1.73	0.27
2	12	3.0	3.32	-0.32
3	15	4.2	4.52	-0.32
4	16	5.0	4.92	0.08
5	18	6.0	5.71	0.29

Passo 2: Calcular a Soma de Quadrados Total (SQT) Mede a variação total dos dados em relação à média $\bar{Y} = 4.04$.

$$SQT = \sum (Y_i - 4.04)^2$$

$$SQT = (2.0 - 4.04)^2 + (3.0 - 4.04)^2 + \cdots + (6.0 - 4.04)^2$$

$$\mathbf{SQT} = 10.032$$

Passo 3: Calcular a Soma de Quadrados do Erro (SQE) Elevamos os erros (da tabela acima) ao quadrado e somamos.

$$SQE = \sum (Y_i - \hat{Y}_i)^2$$

$$SQE = (0.27)^2 + (-0.32)^2 + \cdots + (0.29)^2$$

$$\mathbf{SQE} \approx 0.368$$

Passo 4: Calcular a Soma de Quadrados da Regressão (SQR)

$$SQR = SQT - SQE$$

$$SQR = 10.032 - 0.368 = 9.664$$

Passo 5: Resultado Final (R^2)

$$R^2 = \frac{SQR}{SQT} = \frac{9.664}{10.032} \approx 0.9633$$

Conclusão

O modelo explica 96,33% da variação da renda.

4.6 Pressupostos de uma Regressão Linear

Para que a regressão seja eficiente, os dados precisam seguir 5 pressupostos básicos:

1. **Relação Linear:** O valor a ser predito deve ter relação linear com as variáveis explicativas. *(Verificação: Gráficos de dispersão).*

2. **Ausência de Multicolinearidade:** As variáveis independentes (X) não devem ser altamente correlacionadas entre si (redundância), pois isso torna os coeficientes instáveis. *(Verificação: Matriz de Correlação ou VIF).*

3. **Normalidade dos Erros:** A diferença entre valores reais e preditos deve seguir uma distribuição Normal. *(Verificação: Histograma ou Q-Q Plot).*

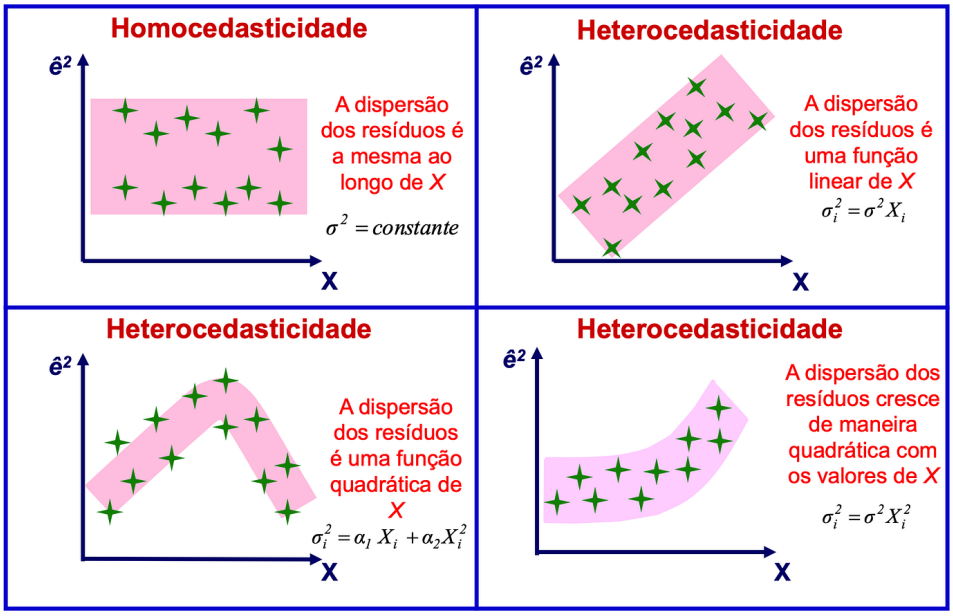

Figura 2: Visualização: Homocedasticidade vs. Heterocedasticidade.

4. **Homocedasticidade:** Os resíduos devem ter variância constante ao longo de todos os níveis de Y. Os pontos no gráfico de resíduos devem estar distribuídos aleatoriamente em torno do zero, sem formar "funis". *(Verificação: Gráfico Resíduos vs. Valores Ajustados).*

5. **Independência dos Erros:** O erro associado a uma observação não pode estar relacionado ao erro de outra (sem autocorrelação).

5 Resolução das Questões Verdadeiro ou Falso

5.1 Questão 1 – Julgue as afirmativas:

a) A probabilidade do erro tipo II só pode ser calculada a partir da definição de possíveis valores para o parâmetro desconhecido.

Resposta: Verdadeiro.
Explicação: O erro tipo II (β) é a probabilidade de não rejeitar H_0 quando H_0 é falsa. Para calculá-lo, precisamos especificar um valor concreto para o parâmetro sob a hipótese alternativa. Sem esse valor, não é possível determinar β.

b) O erro tipo II é definido como a probabilidade de rejeitar a hipótese nula quando a hipótese nula é verdadeira.

Resposta: Falso.
Explicação: Isso é a definição do **erro tipo I** (α). O erro tipo II ocorre quando não rejeitamos H_0 mesmo sendo falsa.

c) O nível de significância de um teste é a probabilidade de rejeitar a hipótese nula quando a hipótese alternativa é verdadeira.

Resposta: Falso.
Explicação: O nível de significância (α) é a probabilidade de rejeitar H_0 quando H_0 é verdadeira. A probabilidade de rejeitar H_0 quando H_1 é verdadeira é o **poder do teste** $(1 - \beta)$.

d) Se o p-valor de um teste é maior do que o nível de significância adotado, rejeita-se a hipótese nula.

Resposta: Falso.
Explicação: A regra é: se p-valor $\leq \alpha$, rejeitamos H_0; se p-valor $> \alpha$, **não rejeitamos** H_0.

e) Suponha que o objetivo seja testar a hipótese nula de que a média populacional μ é igual a 0. Se esta hipótese é rejeitada num teste monocaudal contra a hipótese alternativa de que $\mu > 0$, ela também será rejeitada num teste bicaudal contra a hipótese alternativa de que $\mu \neq 0$, adotando-se o mesmo nível de significância.

Resposta: Falso.
Explicação: No teste monocaudal, a região crítica é toda em uma cauda (ex.: $z > 1.645$ para $\alpha = 5\%$). No bicaudal, o valor crítico é maior ($|z| > 1.96$). Pode ocorrer de rejeitarmos no monocaudal (ex.: $z = 1.8$) mas não no bicaudal. Portanto, não há garantia.

5.2 Questão 2 – Notas de matemática e curso noturno

a) Se $\mu = 530$, a distribuição da média amostral deste grupo de 40 alunos é uma distribuição normal com média 530 e variância 1000.

Resposta: Falso.
Explicação: A média amostral $\bar{X}$ tem média $\mu = 530$, mas sua variância é $\sigma^2/n = 1000/40 = 25$, não 1000.

b) Após terminarem o curso, os 40 alunos obtêm na média uma nota de 320 em matemática. Neste caso, a estatística do teste sugerido pelo estatístico é $t = \frac{493.25}{7.000}$, e podemos afirmar que temos evidência para rejeitar a hipótese nula do teste proposto pelo estatístico no nível de 5% de significância.

Resposta: Falso.
Explicação: A nota média 320 é menor que 500, o que não apoia $H_A : \mu > 500$. Além disso, a estatística fornecida não condiz com os dados. Portanto, não há evidência para rejeitar H_0.

c) O p-valor do teste é 0,081. Neste caso, podemos rejeitar a hipótese nula ao nível de 5% de significância.

Resposta: Falso.
Explicação: Para rejeitar ao nível de 5%, o p-valor deve ser ≤ 0.05. Como $0{,}081 > 0{,}05$, não rejeitamos H_0.

d) Mantendo o nível de significância fixo, para diminuir o poder do teste, o estatístico pode aumentar o tamanho da amostra.

Resposta: Falso.
Explicação: Aumentar o tamanho da amostra **aumenta** o poder do teste. Para diminuir o poder, deve-se reduzir o tamanho amostral.

e) Mantendo o tamanho da amostra fixo, se o estatístico quiser aumentar o poder do teste, ele deve aumentar o nível de significância do teste.

Resposta: Verdadeiro.
Explicação: Aumentar α (ex.: de 5% para 10%) amplia a região crítica, facilitando a rejeição de H_0 e, portanto, aumentando o poder do teste (mas também aumenta o erro tipo I).

5.3 Questão 3 – Proporção de consumidores satisfeitos

a) Para aferir se a percentagem dos consumidores que estão muito satisfeitos é igual a 80%, é possível empregar um teste de hipótese bicaudal.

Resposta: Verdadeiro.
Explicação: Testar se a proporção é igual a um valor versus diferente desse valor é um teste bicaudal ($H_1 : p \neq 0.80$).

b) Assumindo que a variância da proporção é conhecida, a um nível de significância de 5%, é possível rejeitar a hipótese de que 80% dos consumidores estão muito satisfeitos com o serviço.

Resposta: Falso.
Explicação:

$$\hat{p} = 0.73, \quad p_0 = 0.80, \quad n = 100$$
$$Z = \frac{0.73 - 0.80}{\sqrt{\frac{0.80 \times 0.20}{100}}} = \frac{-0.07}{0.04} = -1.75$$

Para teste bicaudal com $\alpha = 5\%$, $|Z_{crtico}| = 1.96$. Como $|Z| = 1.75 < 1.96$, não rejeitamos H_0.

c) Assumindo que a variância da proporção é conhecida, se estivermos interessados em testar se a percentagem dos consumidores que não estão muito satisfeitos com o serviço é menor do que 20%, é possível rejeitar a hipótese nula ao nível de significância de 5%.

Resposta: Falso.
Explicação: Testar se "não satisfeitos« 20% equivale a testar se satisfeitos $> 80\%$. Como $\hat{p} = 0.73 < 0.80$, não temos evidência para $p > 0.80$. Portanto, não rejeitamos H_0.

d) Um intervalo de confiança de 95% para a proporção dos consumidores que estão muito satisfeitos com o serviço incluirá o valor de 80%.

Resposta: Verdadeiro.
Explicação:

$$IC = 0.73 \pm 1.96 \times \sqrt{\frac{0.73 \times 0.27}{100}} \approx 0.73 \pm 0.087 = (0.643, 0.817)$$

O valor 0.80 está dentro do intervalo, portanto o IC inclui 80%.

e) Suponha que estejamos interessados em testar, a um nível de significância de 5%, se a proporção dos consumidores que estão muito satisfeitos com o serviço é menor do que 80%. A probabilidade do erro tipo II não dependerá do valor verdadeiro da proporção.

Resposta: Falso.
Explicação: O erro tipo II (β) varia com o valor verdadeiro do parâmetro. Quanto mais próximo o valor verdadeiro estiver do valor sob H_0, maior será β; quanto mais distante, menor será β.

6 Questão 1 – Teste de hipóteses e p-valor

Enunciado

Considere um teste de hipóteses clássico com nível de significância $\alpha = 5\%$. O pesquisador obtém um p-valor igual a 0,08. Assinale a alternativa correta.

a) Como o p-valor é maior que α, rejeita-se a hipótese nula.

b) Como o p-valor é maior que α, não se rejeita a hipótese nula.

c) O p-valor indica a probabilidade de a hipótese nula ser verdadeira.

d) O p-valor indica a probabilidade de erro tipo II ocorrer.

e) O p-valor é independente da hipótese nula formulada.

Resolução passo a passo

1. Relembrar a regra de decisão com o p-valor

A regra básica dos testes de hipóteses é:

- Se **p-valor** $\leq \alpha \rightarrow$ rejeitamos H_0
- Se **p-valor** $> \alpha \rightarrow$ **não rejeitamos** H_0

2. **Aplicar ao problema**

   - Nível de significância: $\alpha = 0,05$
   - p-valor obtido: $0,08$
   - Comparação: $0,08 > 0,05$

Portanto, **não rejeitamos** H_0.

3. **Analisar cada alternativa**

   - **a)** Falsa – Contradiz a regra básica (quando p-valor $> \alpha$, não rejeitamos).
   - **b)** Verdadeira – Segue exatamente a regra correta.
   - **c)** Falsa – O p-valor **não** é a probabilidade de H_0 ser verdadeira. É a probabilidade de observar dados tão ou mais extremos **assumindo** que H_0 é verdadeira.
   - **d)** Falsa – O erro tipo II (β) é diferente do p-valor. O p-valor está relacionado ao erro tipo I.
   - **e)** Falsa – O p-valor **depende** da hipótese nula, pois é calculado sob a suposição de que H_0 é verdadeira.

Resposta final

Alternativa b) – Como o p-valor é maior que α, não se rejeita a hipótese nula.

7 Questão 2 – Inferência Bayesiana

Enunciado

Considere um problema de inferência Bayesian em que o parâmetro de interesse θ pode assumir apenas dois valores possíveis, θ_1, θ_2. O pesquisador especifica uma distribuição a priori $p(\theta)$ e observa uma amostra x, cuja informação é resumida pela **verossimilhança** $L(\theta|x)$.

Com base nesse contexto, assinale a alternativa correta.

a) Se $L(\theta_1|x) > L(\theta_2|x)$, então necessariamente $p(\theta_1|x) > p(\theta_2|x)$, independentemente da distribuição a priori.

b) A distribuição a posteriori pode ser obtida a partir da relação $p(\theta|x) \propto p(\theta)L(\theta|x)$, sendo a normalização necessária apenas para garantir que as probabilidades somem 1.

c) Quanto maior o tamanho da amostra, menor será sempre a influência da priori sobre a posteriori, independentemente da forma da verossimilhança.

d) Em modelos bayesianos, a verossimilhança mede a probabilidade de o parâmetro assumir determinado valor dado os dados observados.

e) A decisão bayesiana entre θ_1, θ_2 pode ser feita comparando apenas as verossimilhanças, desde que a priori seja uniforme.

Resolução passo a passo

1. Relembrar o Teorema de Bayes

A fórmula fundamental da inferência bayesiana é:

$$p(\theta|x) \propto p(\theta) \times L(\theta|x)$$

onde:

- $p(\theta|x)$ é a distribuição **posteriori**
- $p(\theta)$ é a distribuição **priori**
- $L(\theta|x)$ é a **verossimilhança**

2. Analisar cada alternativa

- **a)** Falsa – A posteriori depende tanto da verossimilhança quanto da priori. Se a priori for muito forte contra θ_1, mesmo com verossimilhança maior, a posteriori pode favorecer θ_2.
- **b)** Verdadeira – Esta é exatamente a expressão do Teorema de Bayes. A constante de normalização serve apenas para que as probabilidades somem 1.
- **c)** Falsa – Embora em geral amostras maiores reduzam a influência da priori, há situações patológicas (ex.: verossimilhança muito "plana"ou informativa em direção diferente) onde a priori ainda mantém influência.
- **d)** Falsa – A verossimilhança é $P(x|\theta)$, ou seja, a probabilidade dos dados **dado** o parâmetro. Já $P(\theta|x)$ é a posteriori.
- **e)** Parcialmente verdadeira, mas não a melhor – Se a priori for uniforme, a posteriori é proporcional à verossimilhança, então comparar verossimilhanças equivale a comparar posteriores. No entanto, a decisão bayesiana formal sempre usa a posteriori. A alternativa **b** é mais correta e geral.

Resposta final

Alternativa b) – A distribuição a posteriori pode ser obtida a partir da relação $p(\theta|x) \propto p(\theta)L(\theta|x)$, sendo a normalização necessária apenas para garantir que as probabilidades somem 1.

8 Questão 3 – Relação entre teste de hipótese e intervalo de confiança

Enunciado

Considere a relação entre testes de hipóteses e intervalos de confiança. Assinale a alternativa correta.

a) Um intervalo de confiança de 95% corresponde exatamente a um teste bilateral com nível de significância de 2,5%.

b) Se um valor pertence ao intervalo de confiança de 95%, então a hipótese nula correspondente deve ser aceita ao nível de 5%.

c) A rejeição da hipótese nula em um teste bilateral de 5% implica que o valor hipotetizado não pertence ao intervalo de confiança de 95%.

d) A relação entre testes e intervalos de confiança só é válida para grandes amostras.

e) Aumentar o nível de confiança reduz a largura do intervalo.

Resolução passo a passo

1. Relembrar a relação fundamental

Existe uma relação direta entre testes de hipóteses e intervalos de confiança:

- Um IC de $(1-\alpha) \times 100\%$ contém todos os valores que **não seriam rejeitados** em um teste bilateral com nível α.
- Rejeitar $H_0 : \theta = \theta_0$ ao nível α é equivalente a θ_0 **não estar** no IC de $1-\alpha$.

2. Analisar cada alternativa

- **a)** Falsa – Um IC de 95% corresponde a um teste bilateral com nível de significância de **5%** (2,5% em cada cauda).
- **b)** Falsa – O termo "aceita"é problemático. O correto é "não rejeita". Além disso, a relação correta é: se θ_0 está no IC de 95%, **não rejeitamos** $H_0 : \theta = \theta_0$ ao nível 5%.
- **c)** Verdadeira – Esta é exatamente a relação: rejeitar H_0 ao nível 5% significa que o valor testado está fora do IC de 95%.
- **d)** Falsa – A relação é geral e vale para qualquer tamanho de amostra. Para pequenas amostras, usamos a distribuição t, mas a lógica é a mesma.
- **e)** Falsa – Aumentar o nível de confiança (ex.: de 95% para 99%) **aumenta** a largura do intervalo, pois queremos maior certeza de capturar o parâmetro.

Resposta final

Alternativa c) – A rejeição da hipótese nula em um teste bilateral de 5% implica que o valor hipotetizado não pertence ao intervalo de confiança de 95%.

9 Questão 4 – Interpretação de intervalo de confiança

Enunciado

Um intervalo de confiança bilateral de 95% para a média populacional é dado por (18,5 ; 21,0). Qual hipótese abaixo seria rejeitada em um teste bilateral ao nível de 5%?

a) $H_0 : \mu = 19$

b) $H_0 : \mu = 20$

c) $H_0 : \mu = 21$

d) $H_0 : \mu = 18,8$

e) $H_0 : \mu = 20,5$

Resolução passo a passo

1. Relembrar a regra de decisão

A relação entre IC e teste de hipóteses nos diz que:

- Se o valor hipotético **está dentro** do IC $\rightarrow$ **não rejeitamos** H_0
- Se o valor hipotético **está fora** do IC $\rightarrow$ **rejeitamos** H_0

2. Analisar cada valor em relação ao IC (18,5 ; 21,0)

- **a)** $\mu = 19 \rightarrow 18,5 < 19 < 21,0 \rightarrow$ **Dentro** $\rightarrow$ Não rejeita
- **b)** $\mu = 20 \rightarrow 18,5 < 20 < 21,0 \rightarrow$ **Dentro** $\rightarrow$ Não rejeita
- **c)** $\mu = 21 \rightarrow 21,0$ é o **limite superior**. Como o intervalo é aberto (parênteses), 21,0 está **fora** $\rightarrow$ **Rejeita**
- **d)** $\mu = 18,8 \rightarrow 18,5 < 18,8 < 21,0 \rightarrow$ **Dentro** $\rightarrow$ Não rejeita
- **e)** $\mu = 20,5 \rightarrow 18,5 < 20,5 < 21,0 \rightarrow$ **Dentro** $\rightarrow$ Não rejeita

3. Observação importante

Na prática estatística, quando o valor testado é exatamente igual a um dos limites do IC, o p-valor do teste bilateral é exatamente igual a α. Nesse caso, ainda rejeitamos H_0 (a regra é p-valor $\leq \alpha$ para rejeitar).

Resposta final

Alternativa c) – $H_0 : \mu = 21$ seria rejeitada.

10 Questão 5 – Teste para média com variância conhecida

Enunciado

Uma indústria afirma que o tempo médio de atendimento telefônico é de 5 minutos. Um auditor coleta uma amostra aleatória de 64 chamadas e obtém tempo médio de 4,6 minutos. Sabe-se que o desvio-padrão populacional é 1,6 minuto. Considere $\alpha = 5\%$. O teste de hipóteses: $H_0 : \mu = 5$ vs. $H_A : \mu < 5$. Sabendo que o valor crítico para um teste unilateral à esquerda com $\alpha = 5\%$ é $-1,645$, assinale a alternativa correta.

a) Não se rejeita H_0, pois a estatística é menor em módulo que o valor crítico.

b) Rejeita-se H_0, pois a estatística pertence à região crítica.

c) Rejeita-se H_0 apenas no nível de 10%.

d) O teste é inconclusivo, pois a variância populacional é desconhecida.

e) O p-valor do teste é maior que 5%.

Resolução passo a passo

1. Calcular a estatística de teste Z

A fórmula para teste Z (variância conhecida) é:

$$Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

Substituindo os valores:

$$\begin{aligned} \bar{x} &= 4,6 \\ \mu_0 &= 5 \\ \sigma &= 1,6 \\ n &= 64 \end{aligned}$$

$$Z = \frac{4,6 - 5}{1,6/\sqrt{64}} = \frac{-0,4}{1,6/8} = \frac{-0,4}{0,2} = -2,0$$

2. Comparar com o valor crítico

- Teste unilateral à esquerda: $H_A : \mu < 5$
- Valor crítico: $Z_{crtico} = -1,645$
- Regra: Rejeitar H_0 se $Z < -1,645$
- Nossa estatística: $Z = -2,0$
- Comparação: $-2,0 < -1,645 \rightarrow$ **Rejeitamos** H_0

3. Analisar as alternativas

- **a)** Falsa – Rejeitamos H_0, e o módulo de Z (2,0) é maior que o módulo do crítico (1,645).
- **b)** Verdadeira – A estatística Z = -2,0 está na região crítica ($Z < -1,645$).
- **c)** Falsa – Rejeitamos ao nível de 5%, não apenas 10%.
- **d)** Falsa – A variância populacional é conhecida ($\sigma = 1,6$).
- **e)** Falsa – Se rejeitamos ao nível 5%, o p-valor é menor que 0,05.

Resposta final

Alternativa b) – Rejeita-se H_0, pois a estatística pertence à região crítica.

11 Questão 6 – Teste F para igualdade de variâncias

Enunciado

Uma empresa de logística deseja comparar a variabilidade do tempo de entrega entre dois centros de distribuição: centro mais antigo (Centro A) e centro recentemente automatizado (Centro B). Foram coletadas amostras aleatórias independentes dos tempos de entrega (em horas), obtendo-se:

- Centro A: $n_1 = 25$, desvio-padrão amostral $S_1 = 4$
- Centro B: $n_2 = 16$, desvio-padrão amostral $S_2 = 2$

Deseja-se testar, ao nível de significância $\alpha = 5\%$, se a variabilidade do tempo de entrega é diferente entre os dois centros. O teste de hipóteses: $H_0 : \sigma_1^2 = \sigma_2^2$ vs. $H_A : \sigma_1^2 \neq \sigma_2^2$.

Sabendo que, para um teste bicaudal ao nível de 5%, os valores críticos são $F_{0,025}(24, 15) = 0,39$ e $F_{0,975}(24, 15) = 2,54$, assinale a alternativa correta.

a) Não se rejeita H_0, pois a estatística do teste é menor que 1.

b) Rejeita-se H_0, pois a estatística do teste pertence à região crítica.

c) Rejeita-se H_0 apenas a um nível de significância maior que 5%.

d) O teste é inconclusivo, pois o tamanho amostral do Centro B é pequeno.

e) O p-valor do teste é maior que 10%.

Resolução passo a passo

1. Calcular a estatística F

No teste F para igualdade de variâncias, sempre colocamos a **maior variância no numerador**:

$$S_1^2 = 4^2 = 16, \quad S_2^2 = 2^2 = 4$$

$$F = \frac{S_1^2}{S_2^2} = \frac{16}{4} = 4,0$$

2. Identificar a região crítica

Para teste bicaudal com $\alpha = 5\%$:

- Limite inferior: $F_{0,025}(24, 15) = 0,39$
- Limite superior: $F_{0,975}(24, 15) = 2,54$
- Região crítica: $F < 0,39$ ou $F > 2,54$

3. Comparar e decidir

Nossa estatística: $F = 4,0$

$$4,0 > 2,54 \Rightarrow \text{Está na região crítica}$$

Portanto, **rejeitamos** H_0 ao nível de 5%.

4. Analisar as alternativas

- **a)** Falsa – Rejeitamos H_0, e F = 4,0 é maior que 1.
- **b)** Verdadeira – F = 4,0 está na região crítica ($> 2,54$).
- **c)** Falsa – Rejeitamos exatamente ao nível 5%.
- **d)** Falsa – O teste é conclusivo com os dados fornecidos.
- **e)** Falsa – Se rejeitamos ao nível 5%, o p-valor é menor que 0,05 (5%).

Resposta final

Alternativa b) – Rejeita-se H_0, pois a estatística do teste pertence à região crítica.

12 Questão 7 – Teste para coeficiente de regressão

Enunciado

Considere o modelo de regressão linear simples estimado por MQO: $\hat{Y}_i = 2,1 + 0,4X_i$, onde Y_i é a variável dependente e X_i é a variável explicativa. Sabe-se que o erro-padrão do estimador $\hat{\beta}_1$ é igual a 0,1. Deseja-se testar, ao nível de significância de 5%, a hipótese: $H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 \neq 0$. Assuma que a estatística de teste possa ser comparada a uma distribuição t com valor crítico aproximado $|t| = 2$. Assinale a alternativa correta.

a) Não se rejeita H_0, pois o coeficiente estimado é pequeno em valor absoluto.

b) Rejeita-se H_0, pois a estatística t é igual a 4.

c) Rejeita-se H_0, pois o intervalo de confiança de 95% para β_1 inclui o valor zero.

d) O teste é inconclusivo, pois não foi informado o valor de R^2.

e) A estatística de teste segue uma distribuição normal padrão, independentemente do tamanho da amostra.

Resolução passo a passo

1. Calcular a estatística t

A estatística t para testar um coeficiente de regressão é:

$$t = \frac{\hat{\beta}_1}{EP(\hat{\beta}_1)}$$

Substituindo os valores:

$$\begin{aligned} \hat{\beta}_1 &= 0,4 \\ EP(\hat{\beta}_1) &= 0,1 \\ t &= \frac{0,4}{0,1} = 4,0 \end{aligned}$$

2. Comparar com o valor crítico

- Teste bilateral ao nível 5%
- Valor crítico aproximado: $|t| = 2$
- Regra: Rejeitar H_0 se $|t| > 2$
- Nossa estatística: $|t| = 4,0 > 2$
- Portanto, **rejeitamos** H_0

3. Analisar as alternativas

- **a)** Falsa – Rejeitamos H_0, e 0,4 não é necessariamente "pequeno".
- **b)** Verdadeira – A estatística t = 4,0 é maior que o crítico 2.
- **c)** Falsa – Se rejeitamos H_0, o IC de 95% **não** inclui zero.
- **d)** Falsa – R^2 não é necessário para testar coeficientes individuais.
- **e)** Falsa – A estatística segue distribuição t de Student, não normal, especialmente em amostras pequenas.

Resposta final

Alternativa b) – Rejeita-se H_0, pois a estatística t é igual a 4.

13 Questão 8 – Cálculo do estimador MQO

Enunciado

Considere o modelo de regressão linear simples: $y_i = \beta_0 + \beta_1 x_i + u_i$. Para uma amostra de $n = 10$ observações, foram obtidos os seguintes resultados:

$$\sum_{i=1}^{10} x_i = 10, \quad \sum_{i=1}^{10} y_i = 400, \quad \sum_{i=1}^{10} x_i y_i = 500, \quad \sum_{i=1}^{10} x_i^2 = 15.$$

Sendo $\hat{\beta}_1$ o estimador de Mínimos Quadrados Ordinários de β_1, assinale a alternativa correta.

a) $\hat{\beta}_1 = \frac{\sum x_i y_i}{\sum x_i^2} = \frac{500}{15} \approx 33,33$

b) $\hat{\beta}_1 = \frac{\sum x_i y_i - \bar{x}\bar{y}}{\sum x_i^2} = \frac{500-40}{15} \approx 30,67$

c) $\hat{\beta}_1 = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2} = \frac{500-400}{15} \approx 6,67$

d) $\hat{\beta}_1 = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2} = \frac{100}{5} = 20$

e) $\hat{\beta}_1 = \frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x})^2} = \frac{100}{10} = 10$

Resolução passo a passo

1. Calcular as médias amostrais

$$\bar{x} = \frac{\sum x_i}{n} = \frac{10}{10} = 1$$
$$\bar{y} = \frac{\sum y_i}{n} = \frac{400}{10} = 40$$

2. Calcular todos os termos necessários para a fórmula

Vamos calcular cada componente separadamente:

Termo do numerador:

$$\sum x_i y_i - n\bar{x}\bar{y} = 500 - (10 \times 1 \times 40) = 500 - 400 = 100$$

Termo do denominador:

$$\sum x_i^2 - n\bar{x}^2 = 15 - (10 \times 1^2) = 15 - 10 = 5$$

Verificar a forma alternativa (opcional):

$$\sum (x_i - \bar{x}) y_i = \sum x_i y_i - \bar{x} \sum y_i = 500 - (1 \times 400) = 500 - 400 = 100$$

$$\sum (x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2 = 15 - 10 = 5$$

3. Aplicar a fórmula correta do MQO

A fórmula correta para $\hat{\beta}_1$ em regressão linear simples é:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}$$

Substituindo os valores calculados:

$$\hat{\beta}_1 = \frac{100}{5} = 20$$

4. **Verificar cada alternativa numericamente**

- **a)** $\frac{500}{15} \approx 33,33$ – Incorreta, usa fórmula simplificada demais
- **b)** $\frac{500-40}{15} = \frac{460}{15} \approx 30,67$ – Incorreta, subtrai $\bar{x}\bar{y}$ mas não multiplica por n
- **c)** $\frac{500-400}{15} = \frac{100}{15} \approx 6,67$ – Incorreta, numerador correto mas denominador errado
- **d)** $\frac{100}{5} = 20$ – Correta, fórmula e cálculo exatos
- **e)** $\frac{100}{10} = 10$ – Incorreta, a forma é válida mas o denominador deveria ser 5, não 10

5. **Explicação do erro na alternativa e**

A alternativa e usa a forma conceitualmente correta:

$$\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})y_i}{\sum(x_i - \bar{x})^2}$$

Mas o cálculo do denominador está errado:

$$\sum(x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2 = 15 - 10 = 5 \quad \text{(não 10)}$$

Portanto, o correto seria:

$$\hat{\beta}_1 = \frac{100}{5} = 20 \quad \text{(não } \frac{100}{10} = 10\text{)}$$

Resposta final

Alternativa d) – $\hat{\beta}_1 = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2} = \frac{100}{5} = 20$

Resolução da Questão Aberta – Comparação de Salários entre Setores

Enunciado Completo

Uma secretaria estadual deseja comparar o salário médio mensal (em milhares de reais) de economistas que trabalham em dois setores distintos: setor público (Grupo 1) e setor privado (Grupo 2). Foram coletadas amostras aleatórias independentes de profissionais de cada setor, obtendo-se os seguintes resultados:

- **Setor público (Grupo 1):** $n_1 = 25$, $\bar{X}_1 = 7.2$, $S_1 = 1.5$
- **Setor privado (Grupo 2):** $n_2 = 20$, $\bar{X}_2 = 8.0$, $S_2 = 2.0$

Deseja-se verificar se o salário médio difere entre os dois setores. Considere nível de significância $\alpha = 5\%$.

Pedidos:

a) Formule claramente as hipóteses nula e alternativa apropriadas para o problema, indicando qual estatística de teste deve ser utilizada para comparar as médias dos dois grupos. Justifique sua escolha com base nas informações disponíveis sobre as variâncias populacionais.

b) Escreva a estatística de teste apropriada e calcule seu valor observado.

c) Para um teste bicaudal ao nível de significância de 5%, utilize a seguinte informação: $t_{0.025} \approx 2.02$. Identifique a região crítica do teste.

d) Compare a estatística observada com a região crítica e tome a decisão estatística correspondente.

e) Interprete o resultado do teste no contexto econômico da comparação salarial entre os dois setores.

Resolução Passo a Passo

a) Formulação das hipóteses e escolha do teste

1. Hipóteses: Queremos testar se há diferença entre as médias salariais dos dois setores. Como não temos direcionalidade prévia (não sabemos qual seria maior), usamos um teste **bilateral**:

$$H_0 : \mu_1 = \mu_2 \quad \text{vs} \quad H_1 : \mu_1 \neq \mu_2$$

Onde:

- μ_1 = salário médio populacional do setor público
- μ_2 = salário médio populacional do setor privado

2. Escolha do teste e justificativa: Precisamos decidir entre três opções:

1. **Teste Z para duas amostras** – Quando as variâncias populacionais são conhecidas (não é o caso).
2. **Teste t combinado (pooled)** – Quando as variâncias são desconhecidas mas iguais.
3. **Teste de Welch** – Quando as variâncias são desconhecidas e diferentes.

Justificativa da escolha:

- As variâncias populacionais (σ_1^2 e σ_2^2) são **desconhecidas**.
- Para verificar se podemos assumir variâncias iguais, olhamos para as variâncias amostrais:
$$S_1^2 = (1.5)^2 = 2.25, \quad S_2^2 = (2.0)^2 = 4.00$$
- A razão entre as variâncias é: $\frac{S_2^2}{S_1^2} = \frac{4.00}{2.25} \approx 1.78$
- Como a razão é maior que 1.5 (regra prática comum), é prudente **não assumir igualdade das variâncias**.

Teste escolhido: **Teste t de Welch (variâncias diferentes)**.

b) Estatística de teste e cálculo

Fórmula do teste de Welch:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

Cálculo passo a passo:

1. **Diferença das médias:**

$$\bar{X}_1 - \bar{X}_2 = 7.2 - 8.0 = -0.8$$

2. **Termos de variância:**

$$\frac{S_1^2}{n_1} = \frac{2.25}{25} = 0.09$$

$$\frac{S_2^2}{n_2} = \frac{4.00}{20} = 0.20$$

3. **Soma das variâncias:**

$$\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2} = 0.09 + 0.20 = 0.29$$

4. **Erro padrão da diferença:**

$$SE = \sqrt{0.29} \approx 0.5385$$

5. **Estatística t de Welch:**

$$t = \frac{-0.8}{0.5385} \approx -1.486$$

Resultado: $t \approx -1.486$

c) Região crítica do teste

Para um teste **bilateral** com $\alpha = 5\%$ e usando a distribuição t de Welch:

1. **Graus de liberdade aproximados (fórmula de Welch-Satterthwaite):**

$$\nu \approx \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$

Calculando:

$$\nu \approx \frac{(0.29)^2}{\frac{(0.09)^2}{24} + \frac{(0.20)^2}{19}} = \frac{0.0841}{\frac{0.0081}{24} + \frac{0.04}{19}} \approx \frac{0.0841}{0.0003375 + 0.002105} \approx \frac{0.0841}{0.0024425} \approx 34.4$$

Arredondamos para $\nu \approx 34$ graus de liberdade.

2. **Valor crítico:** O enunciado fornece $t_{0.025} \approx 2.02$ (para ν suficientemente grande).
3. **Região crítica:**

$$RC = \{t : |t| > 2.02\}$$

Ou seja, rejeitamos H_0 se $t < -2.02$ ou $t > 2.02$.

d) Decisão estatística

Comparando nossa estatística calculada com a região crítica:

$$|t| = 1.486 \quad \text{vs} \quad t_{crtico} = 2.02$$

$$1.486 < 2.02$$

Portanto, **NÃO rejeitamos a hipótese nula H_0** ao nível de significância de 5%.

e) Interpretação econômica

Conclusão estatística: Não há evidência estatística suficiente (ao nível de 5% de significância) para afirmar que os salários médios dos economistas diferem entre os setores público e privado.

Interpretação econômica:

- A diferença observada de R$ 800,00 (7,2 vs 8,0 mil reais) pode ser atribuída à variabilidade amostral.
- Isso não significa que os salários são iguais, apenas que com os dados disponíveis não conseguimos detectar uma diferença estatisticamente significativa.
- Fatores a considerar:
  - O setor privado mostra maior variabilidade salarial ($S_2 = 2.0$ vs $S_1 = 1.5$), o que pode mascarar diferenças de média.
  - Tamanhos amostrais modestos ($n_1 = 25$, $n_2 = 20$) limitam o poder do teste.
  - Outras variáveis não controladas (experiência, qualificação, região) podem influenciar os resultados.

Recomendações para a secretaria:

1. Considerar aumentar o tamanho amostral para obter maior precisão.
2. Controlar por variáveis de confusão (experiência, educação) em uma análise de regressão.
3. Analisar outras medidas além da média, como medianas e percentis, para entender melhor a distribuição salarial.

Resumo dos Resultados

Parâmetro	**Valor**
Diferença observada ($\bar{X}_1 - \bar{X}_2$)	-0.8
Erro padrão da diferença	0.5385
Estatística t de Welch	-1.486
Graus de liberdade aproximados	34
Valor crítico bilateral (5%)	± 2.02
Decisão	Não rejeitar H_0

Observações Adicionais

1. Verificação com teste t combinado (para comparação): Se tivéssemos assumido variâncias iguais:

$$S_p^2 = \frac{(25-1) \times 2.25 + (20-1) \times 4.00}{25+20-2} = \frac{54+76}{43} = \frac{130}{43} \approx 3.023$$

$$t = \frac{-0.8}{\sqrt{3.023 \times (\frac{1}{25} + \frac{1}{20})}} = \frac{-0.8}{\sqrt{3.023 \times 0.09}} = \frac{-0.8}{0.521} \approx -1.535$$

Graus de liberdade: 43, valor crítico = 2.017. Conclusão: mesma decisão (não rejeitar).

2. Intervalo de confiança de 95% (Welch):

$$IC_{95\%} = (\bar{X}_1 - \bar{X}_2) \pm t_{0.025} \times SE$$

$$IC_{95\%} = -0.8 \pm 2.02 \times 0.5385 = -0.8 \pm 1.088 = [-1.888, 0.288]$$

O intervalo inclui o zero, confirmando a não rejeição de H_0.